

# Hortonworks Data Platform (HDP) Sandbox

Victor Manuel Mondragon M. Phd.

Sesión 8 - Lab

Noviembre 30 de 2020





- 1. Conceptos ecosistema Hadoop
- 2. Archivos Distribuidos HDFS
- 3. Procesamiento Distribuido con MapReduce
- 4. Herramientas Hadoop para procesar Datos





HDFS: Sistema de Archivos Distribuido

**MapReduce**: Framework de procesamiento distribuido.

En 2008 como proyecto de código abierto a la fundación Apache.

#### ¿ Que es Hadoop?

Software de código abierto que sirve para almacenar y procesar datos de forma distribuida.



#### ¿Por qué utilizar Hadoop?

- Económico
- Escalabilidad Horizontal (mas ordenadores al Clúster)
  - Crece indefinidamente
- Transparencia en el Clúster
  - Igual en 2 nodos o 200
- Redundante.
  - Cada nodo esta replicado en tres(3) veces por defecto
  - Se puede escoger el nivel de replicación.
- Código Abierto.
  - Contribuciones
- Guarda estructurada o no estructurada



## Conceptos Ecosistema Hadoop II

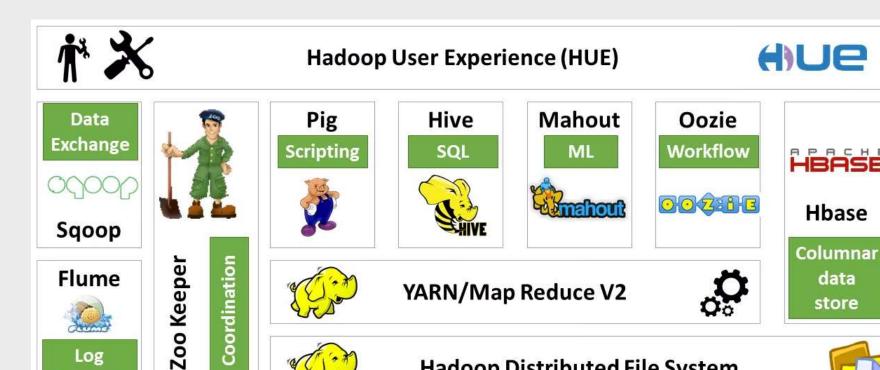


Log

Control

#### Ecosistema de Big Data

store



**Hadoop Distributed File System** 



#### ¿Qué es Amazon EMR?

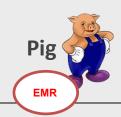
Amazon EMR es una plataforma de clúster administrada que simplifica la ejecución de los marcos de trabajo de Big Data, tales como Apache Hadoop y Apache Spark en AWS para procesar y analizar grandes cantidades de datos.





#### **Arquitectura de Amazon EMR**

Librerías







Motores de Procesamiento



STORM Samza

Gestores de aplicación de Recursos





Ingesta y almacenamient o de datos

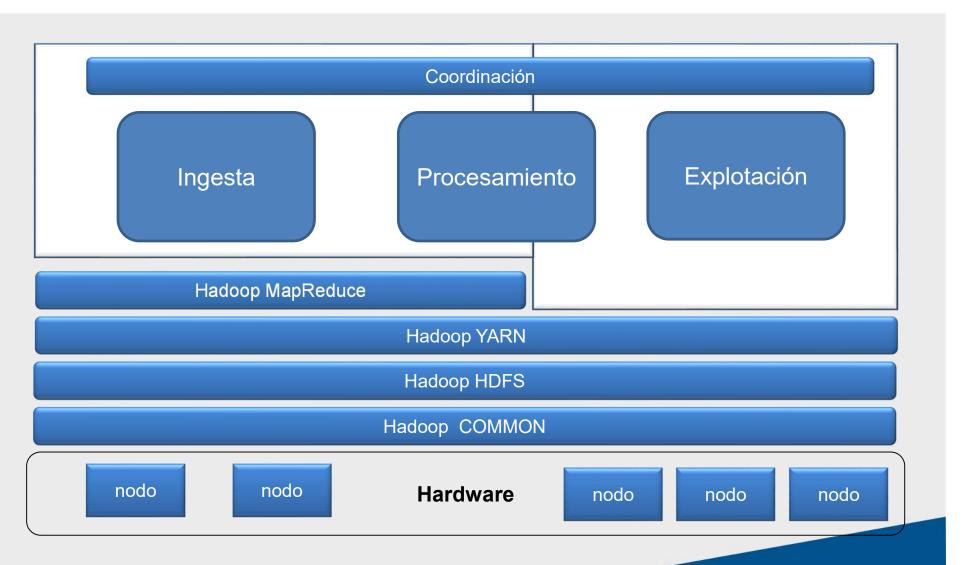








#### **Ecosistema Hadoop**





### Herramientas del Ecosistema

Ingesta, Procesamiento y Explotación



#### Ingesta

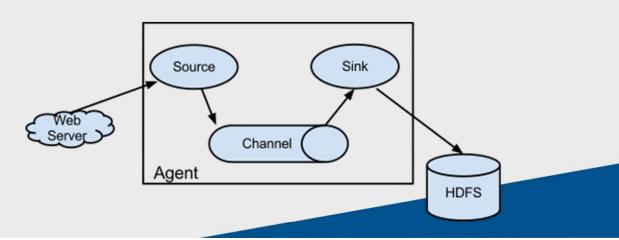


**Sqoop** es una herramienta cuya principal funcionalidad es **importar** datos entre bases de datos relacionales o Data Warehouse y Hadoop.



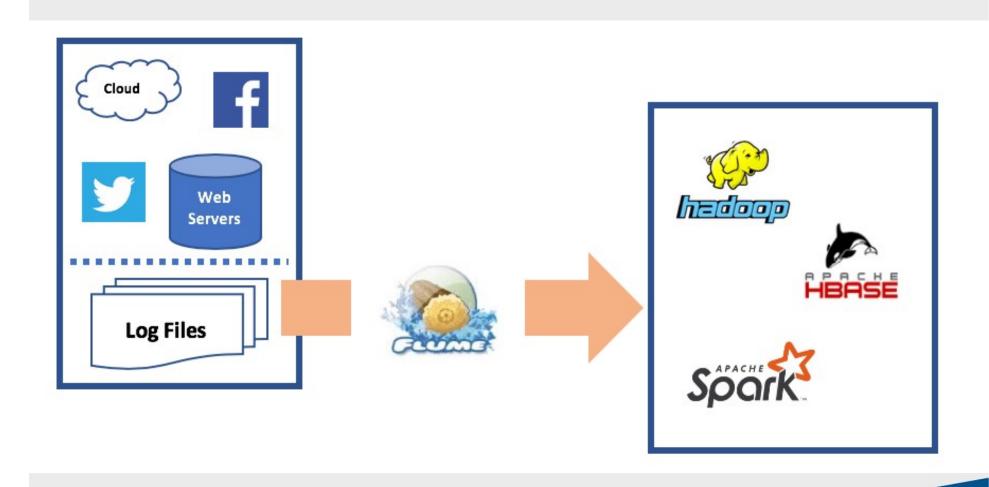
<u>Flume</u> es un servicio distribuido que permite infestar datos en tiempo real.

Herramienta de recopilación de datos de transmisión altamente confiable, distribuida y configurable.



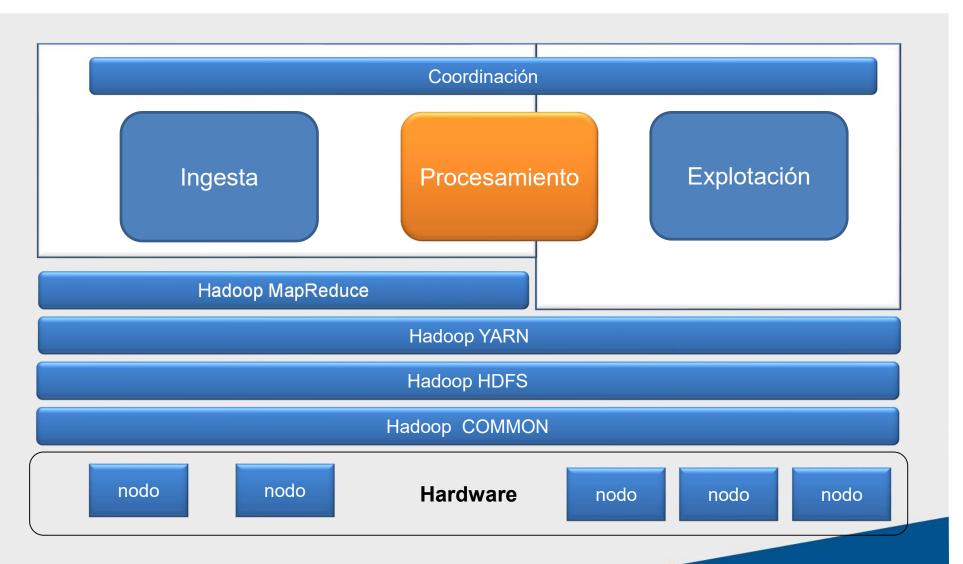


#### Ingesta – Ejemplo Flume





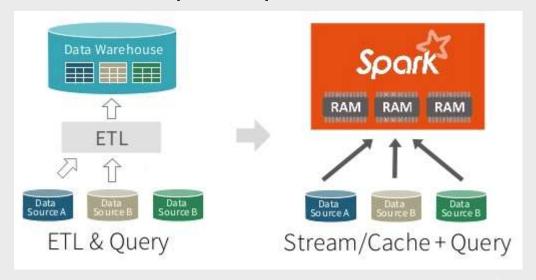
#### **Ecosistema Hadoop**





#### **Procesamiento - SPARK**

**SPARK** es una herramienta de procesamiento de datos que hace un uso intensivo de la memoria por lo que sus cálculos suelen ser mucho más rápidos que los demás medios



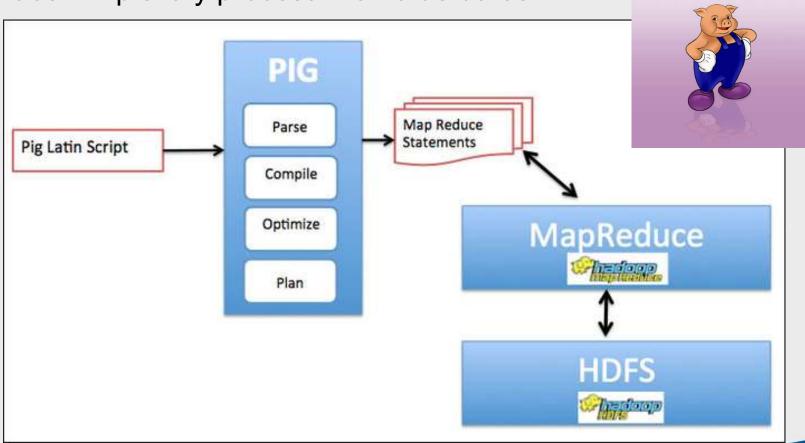
**SPARK** es un motor ultrarrápido para el almacenamiento, procesamiento y análisis de grandes volúmenes de datos.

100 veces mas rápido que MapReduce



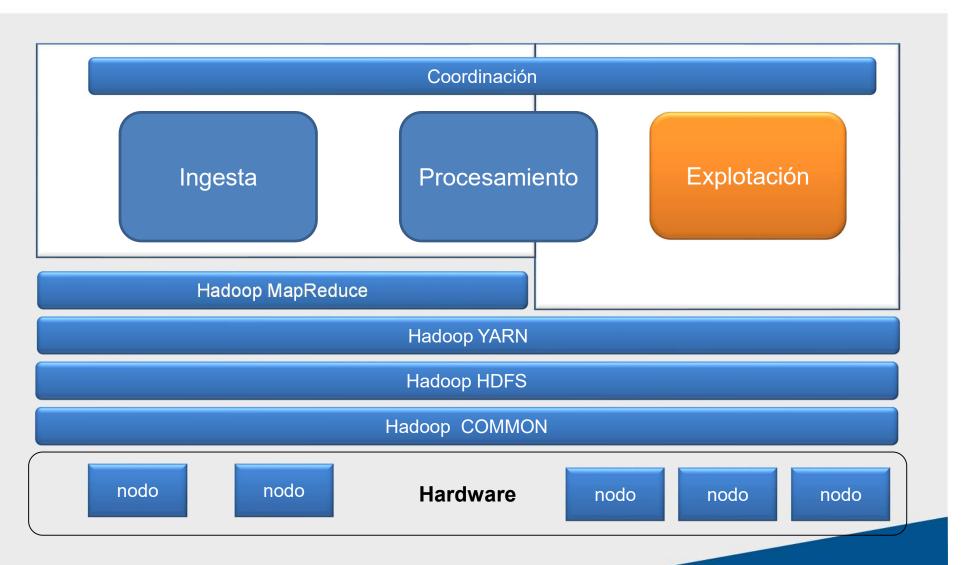
#### Procesamiento - Pig

<u>PIG</u> es una herramienta permite escribir scripts rápidos para hacer limpieza y procesamiento de datos.





#### **Ecosistema Hadoop**





#### **Explotación**

**Explotación** entendemos todo aquello que tiene que ver con el uso final de la información procesada.

Impala: permite realizar consultas en un lenguaje muy similar al SQL de las bases de datos tradicionales las consultas en Impala suelen ser muy rápidas por lo que es posible trabajar con esta herramienta de manera interactiva.

<u>Hive:</u> permite realizar consultas en un lenguaje muy similar al **SQL** de las bases de datos tradicionales, Consultas de **procesamiento**, son mas lentas pero robustas.

<u>HBASE:</u> una base de datos no SQL orientada a columnas, suele utilizarse para servir los datos aplicaciones externas ya que permite leer y escribir información con latencias muy bajas



## Laboratorio Azure Hortonworks Data Platform (HDP) Sandbox

Caso practico Diseñar un almacén de datos Hadoop



#### Crear una cuenta Azure

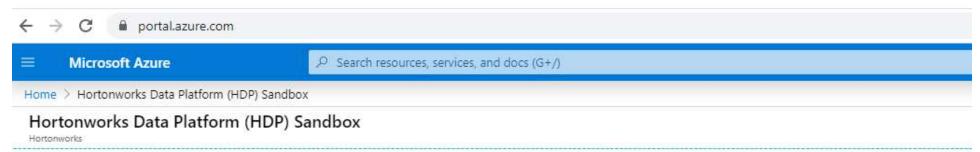
https://azure.microsoft.com/en-us/free/students/

https://azure.microsoft.com/en-us/free/

https://medium.com/@sukhmanjawa/100-credits-with-azure-for-students-without-credit-card-94a09986e0b4



#### **Azure - Hortonworks Data Platform**





#### Hortonworks Data Platform (HDP) Sandbox Save for later

Hortonworks

Create

Start with a pre-set configuration

Want to deploy programmatically? Get started

Overview

Plans

#### About To Deploy?

For a step-by-step guide on how to deploy the Hortonworks Sandbox on Azure, visit: Deploying Hortonworks Sandbox on Microsoft Azure.

Already Set Up and Looking to Learn?

There are a series of tutorials to get you going with HDP fast. To learn more about the HDP Sandbox check out: Learning the Ropes of the Hortonworks HDP Sandbox. To get started using Hadoop to store, process and query data try this HDP 2.6 tutorial series: Hello HDP an introduction to Hadoop

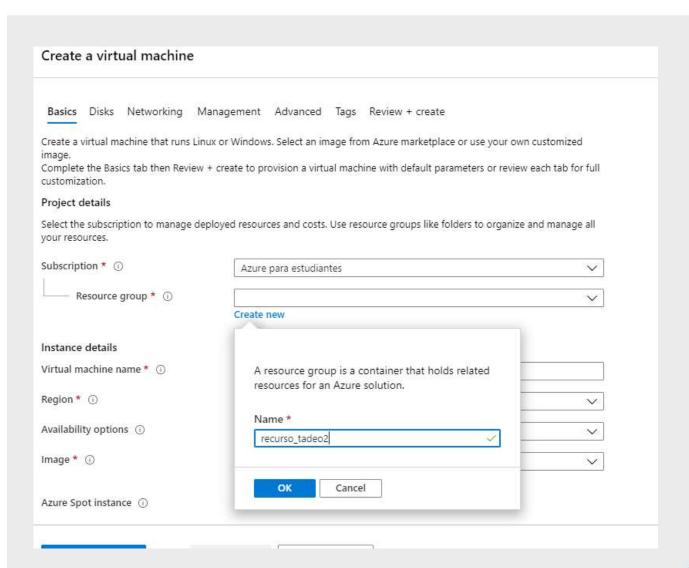
Have Questions?

For all your Hadoop and Big Data questions, and to get answers directly from the pros fast, visit: Hortonworks Community Connection

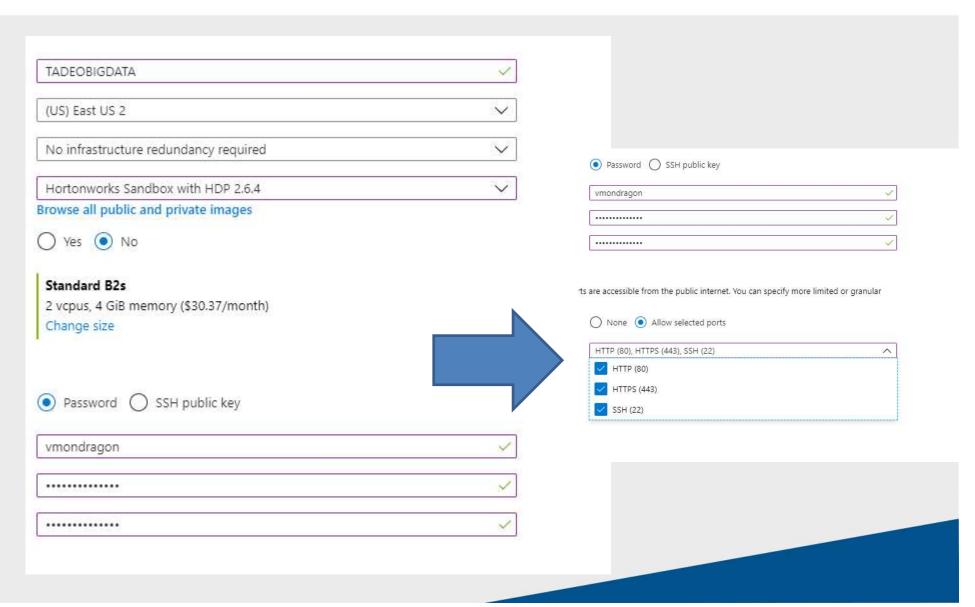
#### Learn More

- Browse: Big Data Tutorials
- · Tutorial: Deploying Hortonworks Sandbox on Microsoft Azure
- Tutorial: Learning the Ropes of the Hortonworks Sandbox

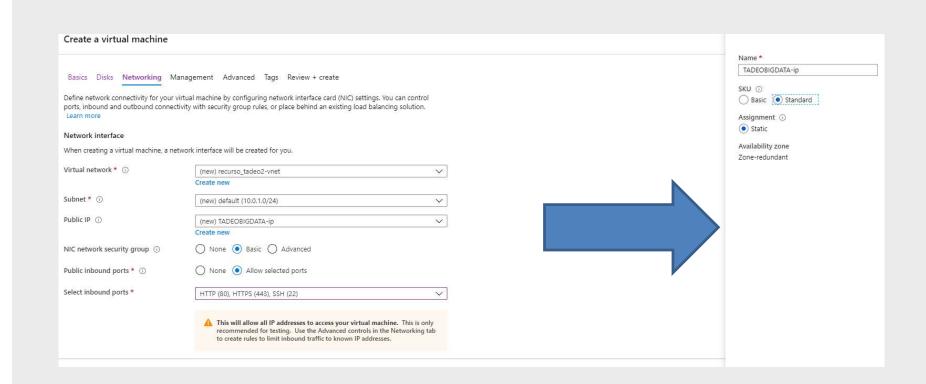




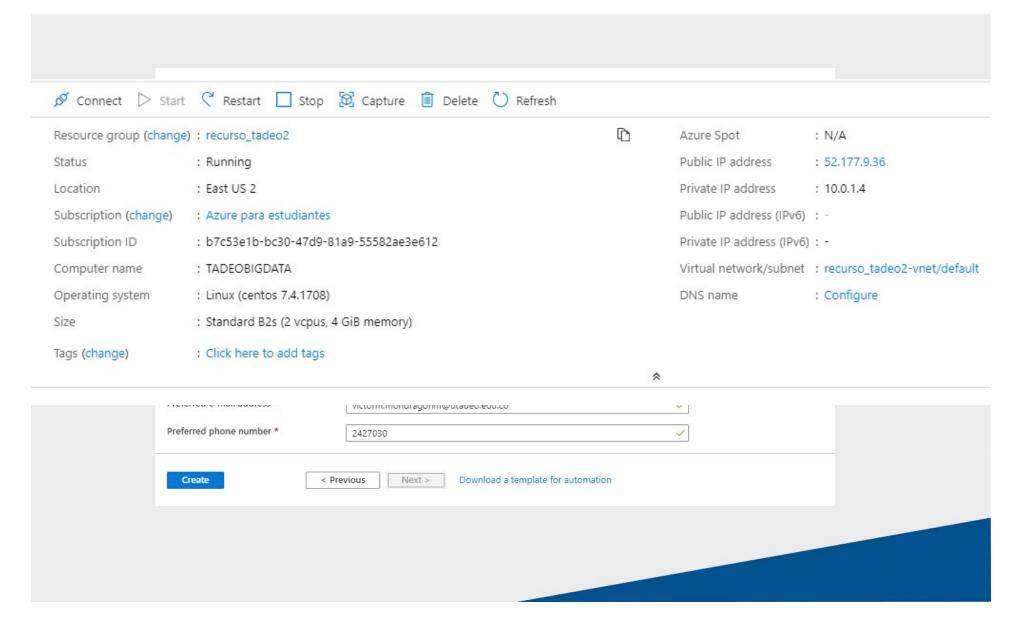




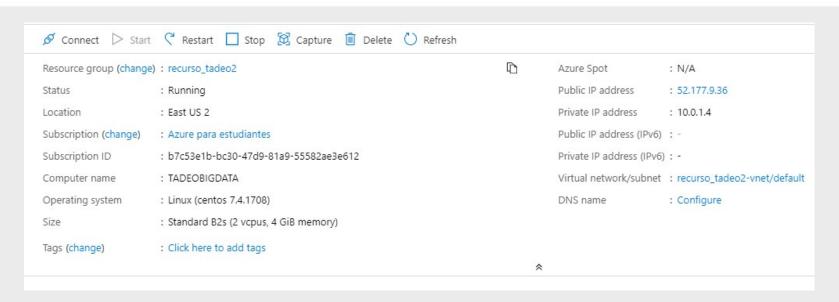


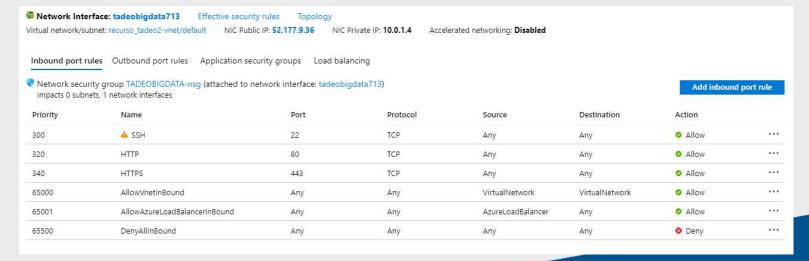






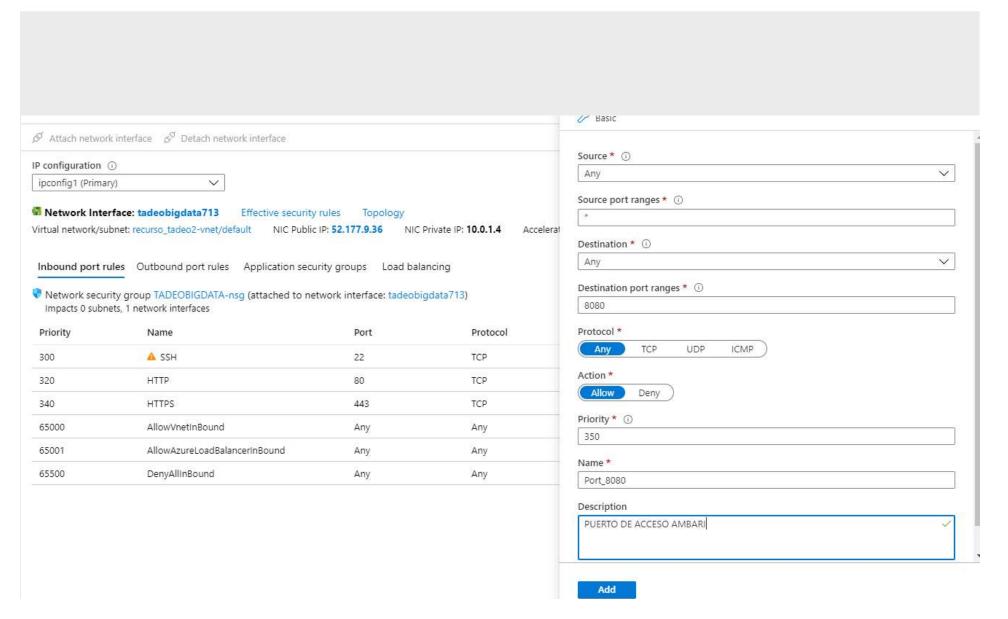






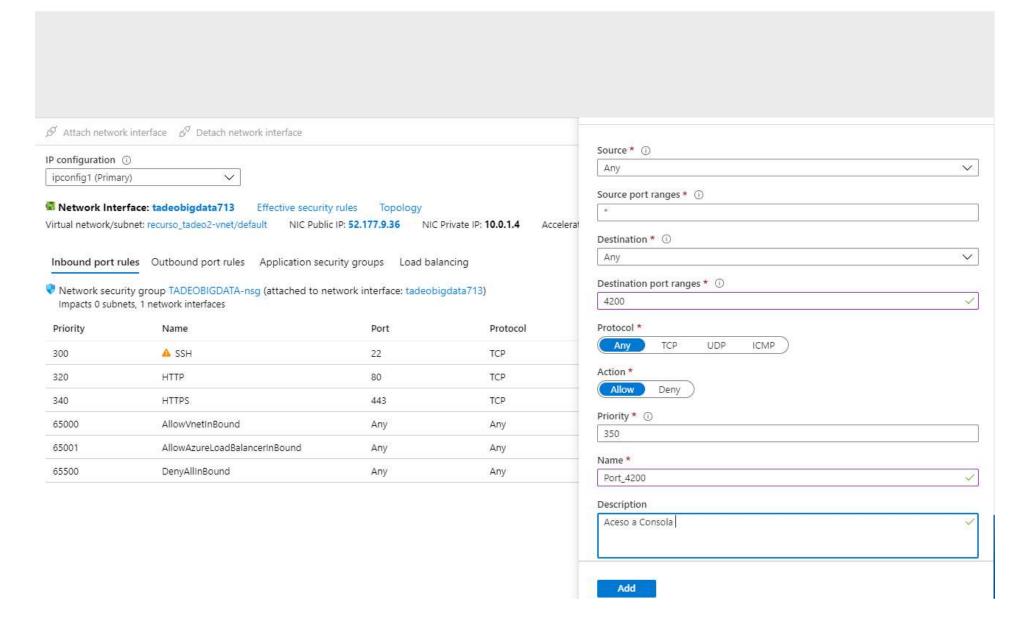


## Agregar puestos de acceso 8080



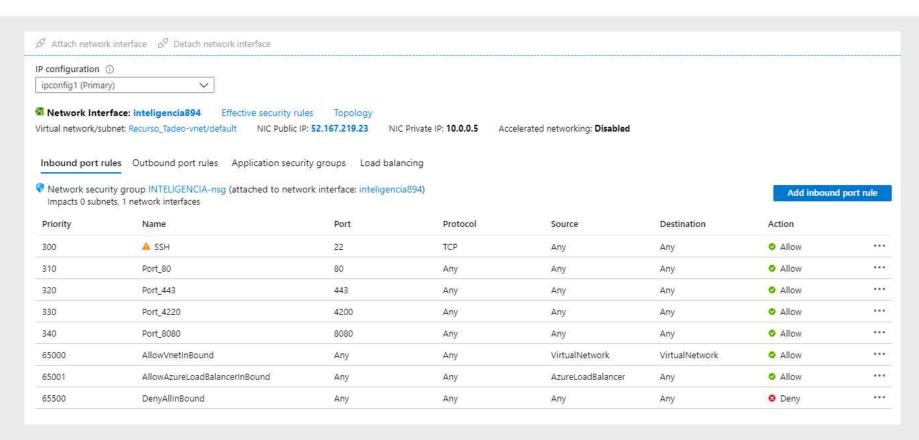


## Agregar puestos de acceso 4200





#### Puertos de Acceso en la Red





#### Acceso a la plataforma

## http://52.177.9.36:4200

La primera vez, ingrese user: root y passwor: hadoop



#### Acceso a la plataforma

### http://52.177.9.36:4200

- La primera vez, ingrese user: root y passwor: hadoop
- Ejecutar el comando: ambari-admin-password-reset
- Cambiar la interfaz de acceso AMBARI WEB

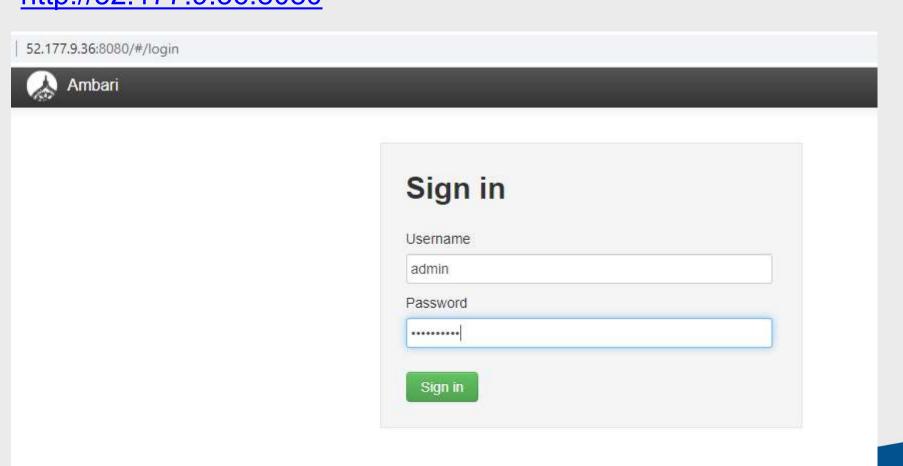
```
← → C ① Not secure | 52.177.9.36:4200
[root@sandbox-hdp ~]# ambari-admin-password-reset Please set the password for admin: Please retype the password for admin:
The admin password has been set.
Restarting ambari-server to make the password change effective...

Jsing python /usr/bin/python
Restarting ambari-server vaiting for server stop...
Ambari Server stopped
Ambari Server running with administrator privileges.
Organizing resource files at /var/lib/ambari-server/resources...
```



#### Acceso a Ambari

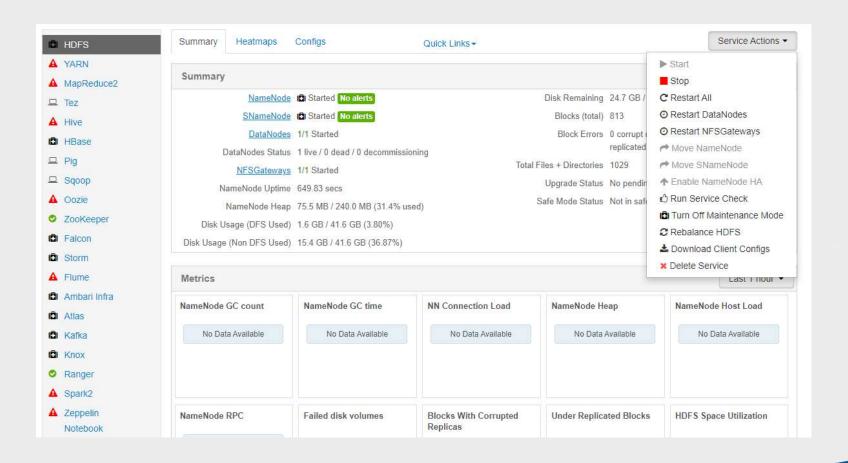
#### http://52.177.9.36:8080





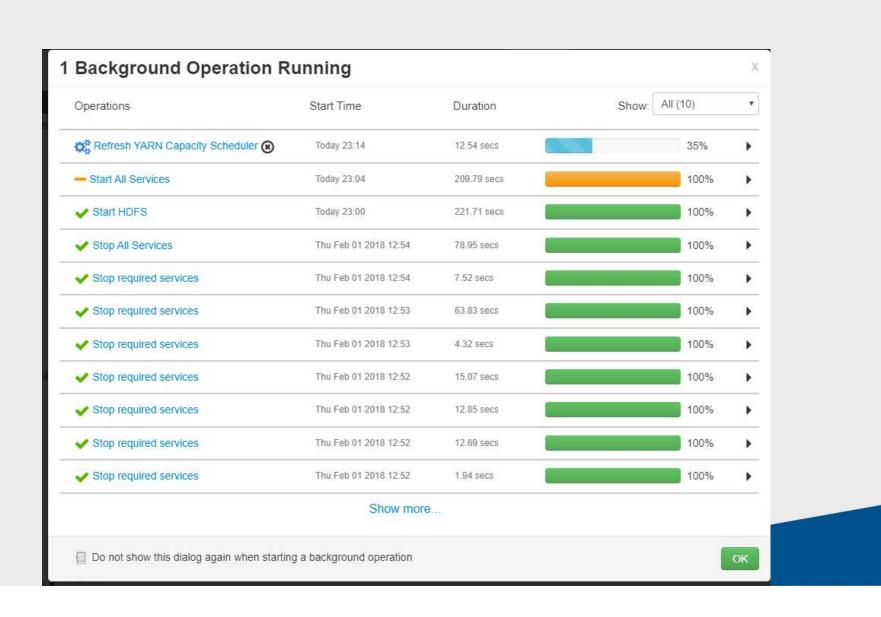
#### **Ambari Sandbox**

#### Activar HDFS – Modo mantenimiento OFF





#### **Ambari Servicios**





## Laboratorio Azure Hortonworks Data Platform (HDP) Sandbox

almacenamiento , procesamiento y consulta de información estructurada en Hadoop



#### **Caso Data WareHouse**

#### **Objetivo**:

Realizar acciones de almacenamiento, procesamiento y consulta de información estructurada en Hadoop.

#### **Tecnologías**:

HDFS y MapReduce Sqoop, Pig, Hive, Impala

#### **Aplicaciones**:

Migrar el almacén de datos (data warehouse) a Hadoop.



#### **Caso Data WareHouse**

 Llevar toda la información dispersa a una plataforma Big Data.

Actividades

 Reducir el tiempo necesario para generar informes requeridos en la organización.

## ☐ Hadoop: Dimensionar un clúster

- □ HDFS: Ingesta con las bases de datos a Hadoop.
- ☐ Hive e Impala: Generar informes mediante consultas SQL



## Necesidades del negocio





#### **Estrategia - Laboratorio Hadoop**

- Definir una estructura de directorios en HDFS
- 2. Importar los datos con Sqoop
- 3. Procesar con MapRecuce y Ping
- 4. Planificar con Oozie
- 5. Consultar con Hive e Impala



#### Origen de los datos –Data WareHouse

Fuente de información de la empresa : Brazilian E-Commerce

https://www.kaggle.com/olistbr/brazilian-ecommerce/

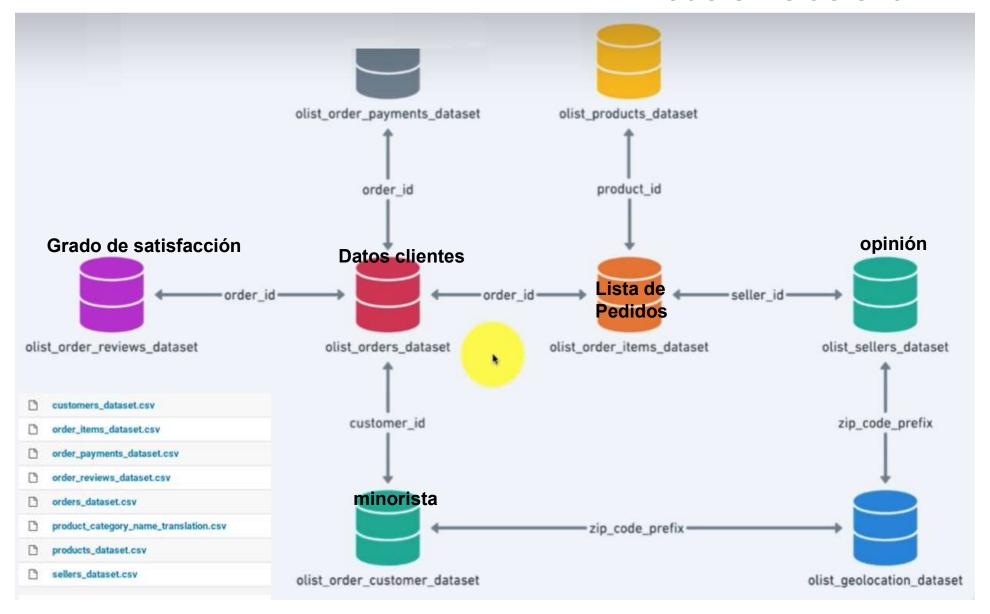
# https://cutt.ly/FtsxMg7

(hadoop\_course-master.zip)

```
cloudera@quickstart:~/workspace/hadoop_course-master/datawarehouse/data
File Edit View Search Terminal Help
[cloudera@quickstart data]$ pwd
/home/cloudera/workspace/hadoop course-master/datawarehouse/data
[cloudera@quickstart data]$ ls -al
total 63372
drwxrwxr-x 2 cloudera cloudera
                                  4096 Jan 3 15:25 .
drwxrwxr-x 5 cloudera cloudera
                                  4096 Jan 3 15:25 ...
-rw-rw-r-- 1 cloudera cloudera 9033957 Jan 3 15:25 customers dataset.csv
-rw-rw-r-- 1 cloudera cloudera 15438671 Jan 3 15:25 order items dataset.csv
-rw-rw-r-- 1 cloudera cloudera 5777138 Jan 3 15:25 order payments dataset.csv
-rw-rw-r-- 1 cloudera cloudera 14409007 Jan 3 15:25 order reviews dataset.csv
-rw-rw-r-- 1 cloudera cloudera 17654914 Jan 3 15:25 orders dataset.csv
-rw-rw-r-- 1 cloudera cloudera
                                  2613 Jan 3 15:25 product category name translation.csv
-rw-rw-r-- 1 cloudera cloudera 2379446 Jan 3 15:25 products dataset.csv
-rw-rw-r-- 1 cloudera cloudera 174703 Jan 3 15:25 sellers dataset.csv
[cloudera@quickstart data]$
```



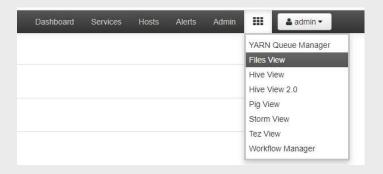
## Explorar archivos de datos HDFS Modelo Relacional

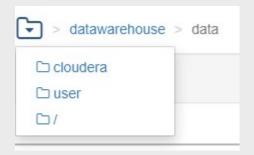




#### Crear la estructura de directorio

#### Crear la ruta, estructura de directorio

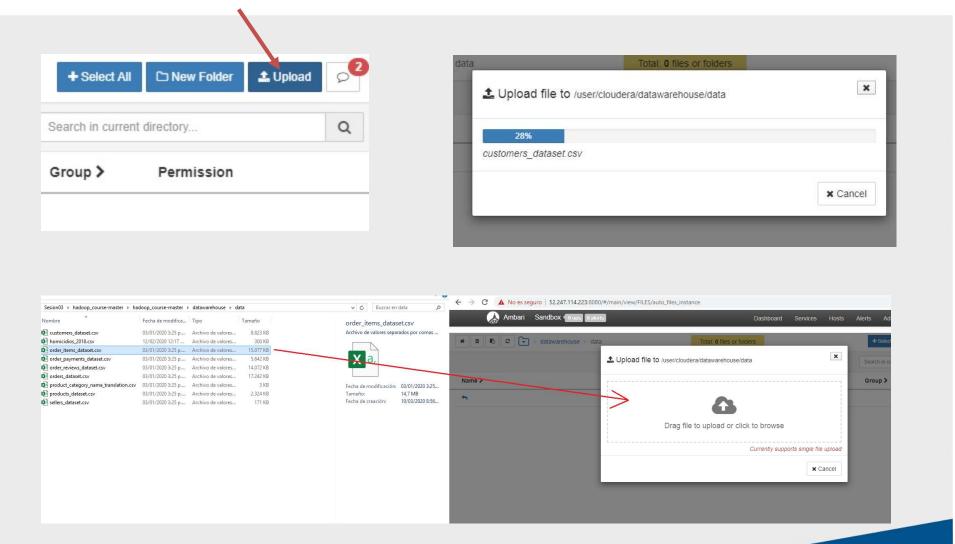






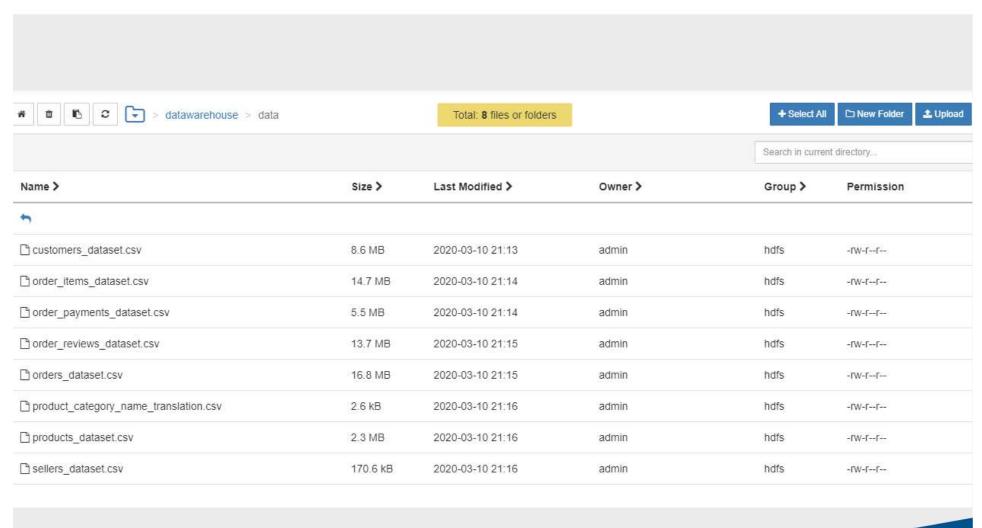


#### Cargar los archivos desde FILE





#### Cargar los archivos desde FILE



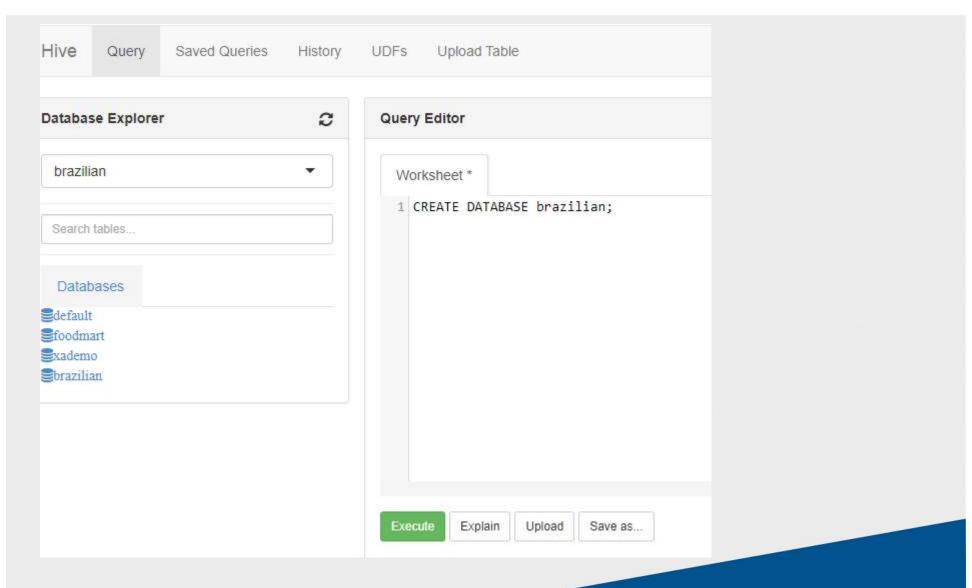


#### Verificar que se encuentra en HDFS

```
root@sandbox-hdp conf]# hadoop fs -ls /user/cloudera/datawarehouse/data
Found 8 items
rwxrwxrwx 1 admin hdfs
                           9033957 2020-03-11 02:13 /user/cloudera/datawarehouse/data/customers dataset.csv
           1 admin hdfs
                          15438671 2020-03-11 02:14 /user/cloudera/datawarehouse/data/order items dataset.csv
rwxrwxrwx
           1 admin hdfs
                           5777138 2020-03-11 02:14 /user/cloudera/datawarehouse/data/order payments dataset.csv
rwxrwxrwx
           1 admin hdfs
                          14409007 2020-03-11 02:15 /user/cloudera/datawarehouse/data/order reviews dataset.csv
rwxrwxrwx
          1 admin hdfs
                          17654914 2020-03-11 02:15 /user/cloudera/datawarehouse/data/orders dataset.csv
rwxrwxrwx
rw-r--r-- 1 admin hdfs
                              2613 2020-03-11 02:16 /user/cloudera/datawarehouse/data/product category name translation.csv
                           2379446 2020-03-11 02:16 /user/cloudera/datawarehouse/data/products dataset.csv
           1 admin hdfs
          1 admin hdfs
                          174703 2020-03-11 02:16 /user/cloudera/datawarehouse/data/sellers dataset.csv
rw-r--r--
root@sandbox-hdp conf]# hadoop fs -ls /user/cloudera/datawarehouse/data
```

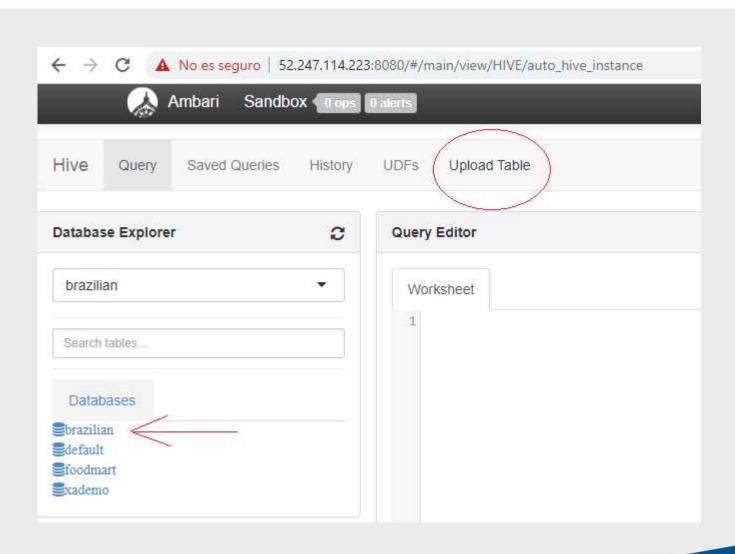


#### Crear una Base en HIVE



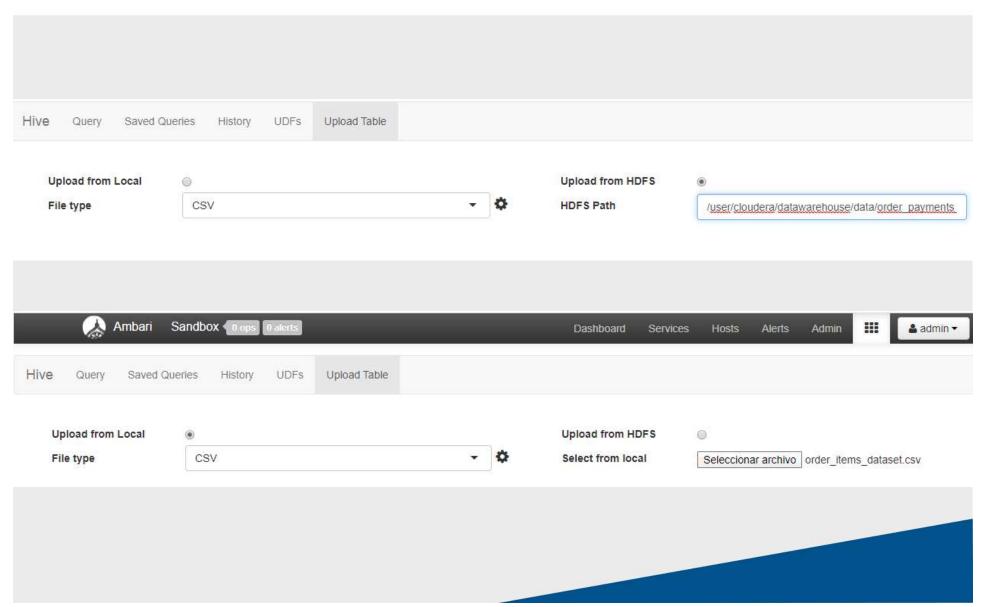


#### Cargar las tablas en la BD – HIVE HDFS



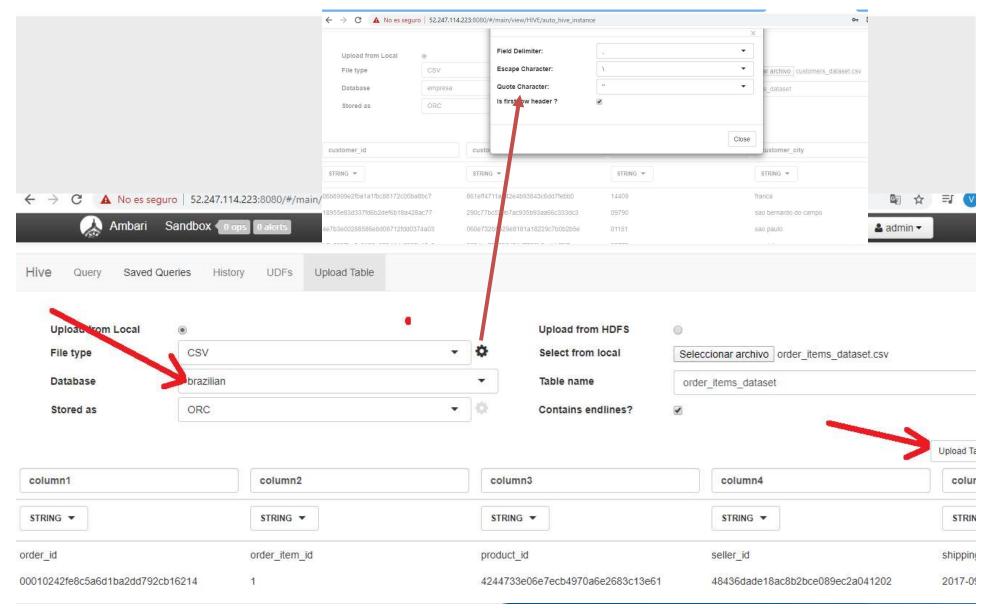


## Cargar las tablas en la BD – HIVE HDFS



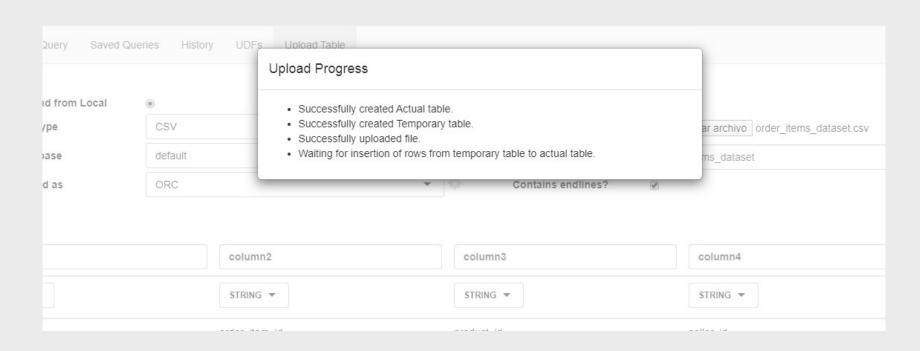


#### Cargar Tabla a DB HDSF





#### **Cargar Tabla a DB HDSF**

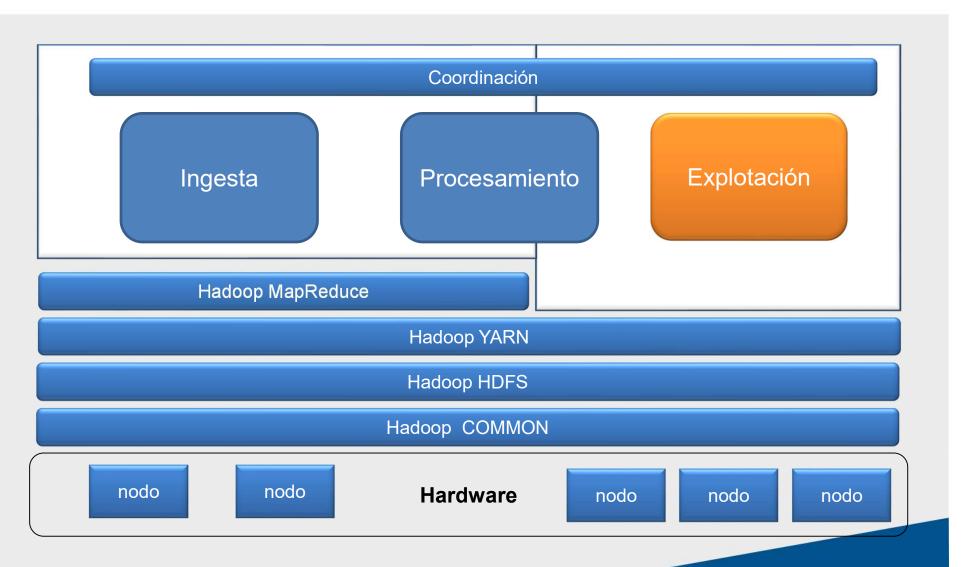


Cargar las tablas por las dos modalidades (10 Minutos)

DROP TABLE IF EXISTS employee;



#### Practica de Explotación - Hadoop





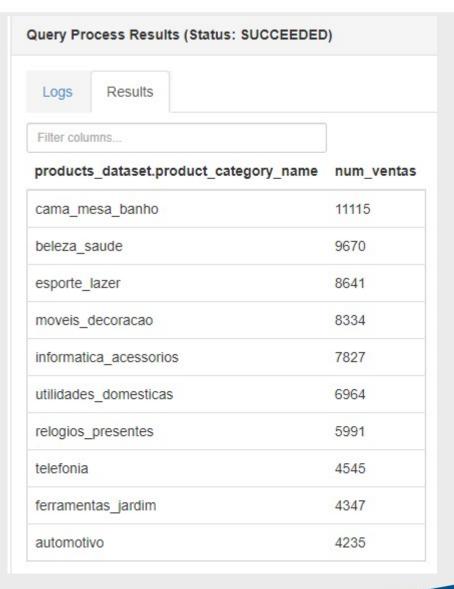
#### **Hive - Consultas para el Negocio**

## TOP 10 de ventas en la empresa

```
-- HIVE Categorías con mayor número de ventas----
SELECT products_dataset.product_category_name,
COUNT(order_items_dataset.product_id) num_ventas
FROM products_dataset JOIN order_items_dataset
ON (products_dataset.product_id = order_items_dataset.product_id)
GROUP BY products_dataset.product_category_name
ORDER BY num_ventas DESC
LIMIT 10;
```



#### **Hive - Consultas para el Negocio**





#### Impala-Consultas para el Negocio

## TOP 10 de ventas en la empresa

-- Categorias con mayor numero de ventas

SELECT p.product\_category\_name categorias , COUNT(o.product\_id) num\_ventas FROM order\_items\_dataset AS o INNER JOIN products\_dataset AS p ON o.product\_id = p.product\_id GROUP BY categoriasorder by num\_ventas DESC LIMIT 10 ;



#### **Hive – Informe Negocio**

#### -- Ingresos en función del mes

SELECT MONTH(orders\_dataset.order\_purchase\_timestamp)
mes, ROUND(sum(order\_items\_dataset.price)) ingresos
FROM orders\_dataset JOIN order\_items\_dataset ON
(orders\_dataset.order\_id=order\_items\_dataset.order\_id)
GROUP BY orders\_dataset.order\_purchase\_timestamp
ORDER BY ingresos DESC;







#### Impala – Informe Negocio

#### -- Ingresos en función del mes

-- Ingresos en funcion del mes SELECT month(orders.order\_purchase\_timestamp) mes, round(sum(order\_items.price)) ingresos FROM orders\_dataset as orders join order\_items\_dataset as order\_items on orders.order\_id=order\_items.order\_id GROUP BY mes ORDER BY ingresos DESC;



#### **Hive – Informe estados**

-- Estados que generan el mayor numero de pedidos SELECT customers.customer\_state, count(\*) num\_orders FROM orders\_dataset as orders
JOIN customers\_dataset as customers on orders.customer\_id=customers.customer\_id
GROUP BY customers.customer\_state
ORDER BY num\_orders DESC
LIMIT 10;



## **Hive – Informe estados - resultado**

customers.customer_state	num_orders
SP	41746
RJ	12852
MG	11635
RS	5466
PR	5045
SC	3637
BA	3380
DF	2140
ES	2033
GO	2020



#### **Ejercicio Taller**

Para las consultas realizadas para Impala contenidas en el archivo:

hadoop\_course-master\datawarehouse\queries \ consultas.sql

Realizar para HIVE, teniendo en cuenta que las diferencias de sintaxis entre IMPALA y HIVE.