

# Estadística bayesiana

Maestría en Modelado y Simulación/ Maestría en Ingeniería y  
analítica de datos

Carenne Ludeña

Departamento de Ciencias Básicas y Modelado  
Facultad de Ciencias Naturales e Ingeniería  
Universidad Jorge Tadeo Lozano



# Probabilidad condicional

- Si  $P(A) \neq 0$ :  $P(B|A) = P(A \cap B)/P(A)$

- 

$$P(A \cap B) = P(A) \times P(B|A)$$

- Variables discretas:  $P(X|Y) = P(X, Y)/P(Y)$
- Variables continuas:  $f(x|y) = \frac{f(x,y)}{f(y)}$
- Mezcla:  $Y$  discreta y  $X$  continua  $X|Y = y \sim f_y(x)$

# Probabilidad total

- Si  $\{A_i\}_i$  es una partición de  $\Omega$
- $P(A) = \sum_i P(A \cap A_i) = \sum_i P(A|A_i)P(A_i)$
- Bayes:  $P(A_i|A) = P(A|A_i)P(A_i)/P(A)$

# Esperanza condicional

- Caso discreto:  $E_{X|Y=y} = \sum_i x_i p(X = x_i | Y = y)$
- Caso continuo o de mezcla:  $E_{X|Y=y} = \int x f(x | Y = y)$
- $E_{X|Y=y}$  es una variable aleatoria: depende del valor de  $Y$
- $E(X) = E(E(X|Y))$
- $Var(X) = E(Var(X|Y)) + Var(E(X|Y))$

# Estadística bayesiana

- Principios: Thomas Bayes (1701–1761)
- Una probabilidad es un grado de creencia. No depende de llevar a cabo un experimento
- Los parámetros que definen una distribución son a su vez variables aleatorias
- la distribución de los parámetros se actualiza a medida que se observa el fenómeno
- Modelo  $X|\theta \sim f(x|\theta)$
- Densidad a priori  $\theta \sim f(\theta)$
- Marginal  $f(x) = \int f(x|\theta)f(\theta)d\theta$
- Densidad a posteriori  $\theta|X \sim \frac{f(x|\theta)f(\theta)}{f(x)}$
- Densidad de predicción  $y|x \sim f(y|x) = \int f(y|x, \theta)f(\theta|x)$

# Verosimilitudes

- Si  $X = (X_1, \dots, X_n)$  muestra independiente
- $L_n(x) = \prod_i f(x_i|\theta)$
- $f(\theta|x) = \frac{f(\theta) \prod_i f(x_i|\theta)}{f(x)}$
- $f(\theta|x) \propto f(\theta)L_n(x)$
- La constante de normalización en general no la usaremos: se buscan maneras de no necesitar la constante de normalización.
- Contar con una distribución a posteriori de  $\theta$  permite cambiar el paradigma de estimación puntual por el conocimiento de la distribución
- Valor medio a posteriori:  $\bar{\theta} = \int \theta f(\theta|x) d\theta$
- MAP:  $\theta$  que maximiza  $f(\theta|x)f(\theta)$
- Intervalo de confianza:  $a, b$  tales que  $\int_a^b f(\theta|x) = 1 - \alpha$
- Se puede estimar el intervalo de confianza usando los cuantiles estimados usando la distribución

# Ejemplo Bernoulli

- $p \sim Unif(0, 1)$ ,  $X|p \sim Ber(p)$
- $X_1, \dots, X_n$ ,  $S = \sum_i X_i$
- $f(p|X) \sim Beta(S + 1, n - S + 1)$
- $Z \sim Beta(\alpha, \beta)$ :  $f(z) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} z^{\alpha-1} z^{\beta-1}$  y  $E(Z) = \frac{\alpha}{\alpha+\beta}$ . La uniforme es un caso especial de una Beta.
- $\bar{p} = \frac{S+1}{n+2}$
- $\bar{p} = \lambda_n \hat{p} + (1 - \lambda) \tilde{p}$
- Con  $\hat{p} = S/n$ ,  $\tilde{p} = 1/2 = E(p)$ ,  $\lambda_n = n/(n + 2)$
- Si las distribuciones previas y posteriores pertenecen a la misma familia se dice que la previa es conjugada con respecto al modelo.

# Ejemplo Bernoulli

Graficar betas

```
library(stats)
par(mfrow=c(3,2))
x=seq(0,1,by=0.1)
alpha=c(0,2,10,20,50,500)
beta=c(0,2,8,11,27,232)
for(i in 1:length(alpha)){
y<-dbeta(x,shape1=alpha[i],shape2=beta[i])
plot(x,y,type="l")
}
```



# Ejemplo Gaussiano

- $\theta \sim N(a, b^2), X|p \sim N(\theta, \sigma^2)$
- $X_1, \dots, X_n, \bar{X} = \sum_i X_i / n$
- $f(\theta|X) \sim N(\bar{\theta}, \tau^2)$
- $\bar{\theta} = w\bar{X} + (1 - w)a$
- $w = \frac{\frac{n}{\sigma^2}}{\frac{n}{\sigma^2} + \frac{1}{b^2}}$
- $\frac{1}{\tau^2} = \frac{n}{\sigma^2} + \frac{1}{b^2}$
- $w \rightarrow 1$  cuando  $n \rightarrow \infty$ , pero si  $b \rightarrow \infty$  produce el mismo efecto (o muchos datos o una previa muy poco informativa)
- El intervalo de confianza se calcula con los parámetros de la normal:  
 $[\bar{\theta} - \tau * q_{1-\alpha/2}, \bar{\theta} + \tau * q_{1-\alpha/2}]$

# propiedades de muestras grandes

- Sea  $\hat{\theta}$  el estimador máximo verosímil (maximiza la verosimilitud)
- Sea  $s = \sqrt{(\text{Var}(\hat{\theta}))}$
- Entonces  $C_n = [\hat{\theta} - q_{1-\alpha/2}s, \hat{\theta} + q_{1-\alpha/2}s]$  es el intervalo de confianza clásico
- Se tiene que  $P(\theta \in C_n | X) \rightarrow 1 - \alpha$

# Previas no informativas e impropias

- Previas no informativas: que no dicen mucho
- Ejemplo Bernoulli  $p \sim \text{Unif}(0, 1)$
- Ejemplo Gaussiano  $b \rightarrow \infty$
- Se usan cuando no sabemos mucho
- Previas impropias: no integran  $\int f(\theta) d\theta = \infty$

# Pruebas de hipótesis Bayesianas


- Se necesita una previa para  $\theta$  bajo cada hipótesis (nula y alternativa)
- Se incluye también una previa sobre las hipótesis: por ejemplo  
 $P(H_0) = P(H_1) = 1/2$
- Ejemplo:  $H_0 : \theta = \theta_0$ ,  $H_1 : \theta \neq \theta_0$
- Bajo  $H_1$ :  $f(\theta)$  es la previa para  $\theta$
- $$P(H_0|X) = \frac{f(x|H_0)P(H_0)}{f(x|H_0)P(H_0) + f(x|H_1)P(H_1)} = \frac{f(x|\theta_0)}{f(x|\theta_0) + \int f(x|\theta)f(\theta)d\theta}$$
- Esto produce resultados diferentes a los usuales!

# Pruebas de hipótesis Bayesianas

Factor de bayes (BF)

$$BF = \frac{P(H_0|X)}{P(H_1|X)} / \frac{P(H_0)}{P(H_1)}$$

Para rechazar  $H_0$ , BF debe ser pequeña ( $< 0.05, 0.1$ )



# Estimadores de Bayes

- Funciones de riesgo  $R(\theta, \hat{\theta}) = E(L(\theta, \hat{\theta})) = \int L(\theta, \hat{\theta}(x))f(x|\theta)dx$ , con  $L$  una función de pérdida
- Visión clásica: minimizar una cota superior de  $R(\theta, \hat{\theta})$ .  
$$\tilde{\theta} = \min \max_{\theta} R(\theta, \hat{\theta})$$
- Enfoque bayesiano: minimizar la esperanza con respecto a la distribución de  $\theta$
- $R_B(f, \hat{\theta}) = \int R(\theta, \hat{\theta})f(\theta)d\theta$
- Este estimador se llama el estimador de Bayes